

# Análisis Matemático para Inteligencia Artificial

Martín Errázquin (merrazquin@fi.uba.ar)

Especialización en Inteligencia Artificial

Clase 3

El mundo del Data Science y las competencias de Machine Learning cobraron mucha relevancia con la [competencia de Netflix](#), que prometía **1M USD** a quien pudiera obtener una performance de un 10% por sobre su algoritmo de base para el problema de recomendación de películas.

En este contexto surgió una nueva variante de modelo en base a factorización de matrices.

¿Lo interesante? Con las dos clases de AM ya nos alcanza para entenderlo!

## ¿Por qué funciona la inversa? (1/2)

Demostremos que:

$$\forall x \neq \vec{0} \quad x^T A x > 0$$

Si  $A \in \mathbb{R}^{n \times n}$  es una matriz definida positiva, entonces es invertible:

Dem.: (por método del absurdo)

Supongamos que el determinante de  $A$  es cero, y llegaremos a una solución absurda.

$$\det(A) = 0 \Leftrightarrow \nexists A^{-1} \Leftrightarrow \exists \tilde{x} \neq \vec{0} / A\tilde{x} = \vec{0}$$

Si  $\det(A) = 0$  y queremos resolver un sistema  $Ax = 0$  significa que además de la solución trivial hay infinitas soluciones, es decir  $\text{rango}(A) < n$ , entonces

$$\exists \tilde{x} \neq 0 : A\tilde{x} = 0 \Rightarrow \tilde{x}^T A\tilde{x} = \tilde{x}^T 0 = 0$$

y entonces no se cumple que  $\tilde{x}^T A\tilde{x} > 0$ .

$A$  no es invertible  $\Rightarrow A$  no es def. pos.



$A$  es def. pos.  $\Rightarrow A$  es invertible

## ¿Por qué funciona la inversa? (2/2)

Demostremos que:

$$\sum x_i \cdot x_i^T + \lambda I_k = x_1 x_1^T + x_2 x_2^T + \dots + \lambda I_k$$

$A = x \cdot x^T + \lambda I_k$  es definida positiva, es decir,  $y^T A y > 0$ ,  $\forall y \in \mathbb{R}^k - \{0\}$

Dem.: Sea  $y \in \mathbb{R}^k - \{0\}$

$$y^T A y = y^T (x \cdot x^T + \lambda I_k) y = \underbrace{y^T x}_{n \times 1} \underbrace{x^T y}_{1 \times n} + \underbrace{y^T \lambda I_k y}_{\mathbb{R}^{k \times k}} \quad \begin{matrix} \lambda \cdot y^T \cdot I_k \cdot y \\ \lambda \cdot y^T \cdot y \end{matrix}$$

(recordemos que el p.i. es  $\langle u, v \rangle = u^T v$ ), prop. asociativa,

$$\underbrace{\langle y, x \rangle}_{\text{blue}} \underbrace{\langle x, y \rangle}_{\text{orange}} + \lambda \underbrace{\langle y, y \rangle}_{\text{green}} = \underbrace{\langle x, y \rangle^2}_{\geq 0} + \lambda \underbrace{\|y\|^2}_{\geq 0} > 0.$$

$\therefore x \cdot x^T + \lambda I_k$  es definida positiva.

$$\underbrace{\geq 0}_{\geq 0} + \underbrace{\geq 0}_{\geq 0} > 0 \quad \checkmark$$

# Proyección Ortogonal

$$\text{Proyección} \quad \begin{aligned} s &= \Pi(v) \quad \forall s \in S \\ \Pi(s) &= s \end{aligned}$$

Sea  $\mathbb{V}$  un EV y  $S \subset \mathbb{V}$  un SEV. Una transformación lineal  $\Pi : \mathbb{V} \rightarrow S$  es una proyección si  $\Pi^2 = \Pi \circ \Pi = \Pi$

Esto significa que la matriz de transformación asociada a la proyección cumple con la propiedad de idempotencia:  $[\Pi]^2 = [\Pi]$ .


## Proyección Ortogonal

Dado  $\mathbb{V}$  un EV con p.i. y  $S \subset \mathbb{V}$  un SEV, el objetivo es dado  $v \in \mathbb{V}$  hallar  $\tilde{v} \in S$  que sea “lo más parecido posible” a  $v$ .

$$\tilde{v} \in S : \tilde{v} = \arg \min_{s \in S} \|v - s\|$$

Además vale que  $\langle v - \tilde{v}, s \rangle = 0, \quad \forall s \in S$

Obs: La ortogonalidad de la proyección tiene que ver con el p.i. que se use.



# Teorema de proyección

Sea  $\mathbb{V}$  un EV de dimensión finita con p.i.  $\langle \cdot, \cdot \rangle$ ,  $S$  un SEV. Dado  $v \in \mathbb{V}$  existe un único  $\tilde{v} \in S$  tal que

$$\|v - \tilde{v}\| \leq \|v - u\|, \quad \forall u \in S$$

¿Cómo hallar la proyección?

Sea  $\mathbb{V}$  un EV de dimensión  $n$  con p.i.  $\langle \cdot, \cdot \rangle$ , y  $S \subset \mathbb{V}$  un SEV,  $\dim(S) = m \geq 1$ , y sea  $B = \{s_1, \dots, s_m\}$  una BON de  $S$ . Buscamos encontrar la proyección de  $\tilde{v} \in S$  de  $v \in \mathbb{V}$  ( $\tilde{v} = \Pi_S(v)$ ).

Como  $\tilde{v} \in S$ ,  $\tilde{v} = \sum_{i=1}^m \alpha_i s_i \Rightarrow$  busco los coeficientes que minimizan  $\|v - \sum_{i=1}^m \alpha_i s_i\|$ . El problema puede escribirse como:

$$\tilde{v} = \Pi_S(v) = \sum_{i=1}^m \alpha_i s_i = B\alpha, \quad B = [s_1, \dots, s_m], \quad \alpha = [\alpha_1, \dots, \alpha_m]^T$$

$B = \begin{pmatrix} | & & | \\ s_1 & \dots & s_m \\ | & & | \end{pmatrix} \in \mathbb{R}^{n \times m} \quad \alpha = \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix} \in \mathbb{R}^m$

## ¿Cómo hallar la proyección?

Como por definición  $\langle v - \Pi_S(v), s \rangle = 0, \forall s \in S$ , debo resolver el siguiente sistema de ecuaciones:

$$v - \tilde{v} \in S^\perp \Rightarrow \forall s_i \in B \quad v - \tilde{v} \perp s_i$$

hacer p.i. canónicas

$$\langle x, y \rangle = x^T y = y^T x$$

$$\begin{cases} \langle v - \Pi_S(v), s_1 \rangle = 0 \\ \vdots \\ \langle v - \Pi_S(v), s_m \rangle = 0 \end{cases} \Rightarrow \begin{cases} s_1^T (v - B\alpha) = 0 \\ \vdots \\ s_m^T (v - B\alpha) = 0 \end{cases} \Rightarrow \begin{pmatrix} -s_1^T \\ \vdots \\ -s_m^T \end{pmatrix} (v - B\alpha) = 0$$

$$B^T \leftarrow B = \begin{pmatrix} | & & | \\ s_1 & \dots & s_m \\ | & & | \end{pmatrix}$$

$$B^T (v - B\alpha) = 0 \Leftrightarrow B^T v = B^T B \alpha \Leftrightarrow \alpha = (B^T B)^{-1} B^T v$$

$$\Pi_S = B(B^T B)^{-1} B^T$$

$$\tilde{v} = B \cdot \alpha = B(B^T B)^{-1} B^T \cdot v = \Pi_S \cdot v$$

Observación: Si  $B$  es una BON entonces  $P_{\Pi_S} = BB^T$ .

# Aplicación: Cuadrados Mínimos



$$Ax=b \Rightarrow x=A^{-1}b \quad \text{sólo } \exists A^{-1} \Leftarrow A \text{ cuadrada}$$

Supongamos que tenemos un sistema sobredeterminado de la forma:

$$Ab=y, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^n, \quad y \in \mathbb{R}^m, \quad m > n.$$

$$\min_{s \in S} \|\hat{y} - y\| \quad v \in V$$

$b$  es la solución de cuadrados mínimos

Como  $m > n$ , puede que no exista  $b$  que satisfaga todas las  $m$  ecuaciones, entonces busco la solución que más se acerque (busco  $\text{Proy}_{\text{Col}(A)}y$ )

$$b = \underbrace{(A^T A)^{-1} A^T y}_{\hat{\beta}} \Rightarrow P = \underbrace{A(A^T A)^{-1} A^T}_{\Pi_S}$$

$$\hat{y} = B \cdot d = A \cdot \hat{\beta}$$



Ya vimos que el ajuste por cuadrados mínimos funciona en la teoría, ahora veámoslo funcionar en la práctica!